universidade de aveiro deti departamento de electrónica, telecomunicações e informática

# Assignment 2

## Recuperação de Informação

Trabalho realizado por:

- Lucas Barros nmec : 83895

- Pedro Cavadas nmec : 85090

# Introdução

O principal objetivo deste trabalho é o de criar um programa que processa vários documentos de texto e analise os campos PMID e TI. De seguida são extraídos tokens, ou seja, palavras chave de maneira a auxiliar a implementação de um mecanismo de busca numa fase posterior.

Este trabalho também ajuda a perceber as tarefas que estão por detrás dos melhores motores de busca da atualidade como o Google, sempre que se escreve uma Query e se pressiona ENTER.

A linguagem de Programação adotada foi Python 3 por ser simples, e por desempenhar as funções de processamento de texto (strings) com grande eficiência.

# Conceitos Teóricos

## Tokenization

Tokenization é o processo de converter uma sequência de caracteres de entrada em tokens de saída. Este processo tem normalmente um conjunto de subprocessos/regras associados que vão depender de Tokenizer para Tokenizer. Neste projeto, utilizamos 2 Tokenizers para fazer comparações.

## Indexer

Indexer é uma estrutura de dados que permite que objetos estejam guardados como listas. Neste caso, o nosso Indexer pode ter um dos seguintes formatos:

1. “{ token : { doc_id : count, ... }, ... }”
2. “{ token : (idf, { doc_id : (weight, count), ... }, ... }”
3. “{ token : { doc_id : [index1, index2, ...], ... }, ... }”
4. “{ token : (idf, { doc_id : (weight, [index1, index2, ...]), ... }, ... }”

O primeiro e segundo formato, não contém o índice das posições onde o token aparece no dado documento, já o terceiro e o quarto contém. Por outro lado, no segundo e no quarto foi calculado o tfidf que permite atribuir um ranking a um documento para um dado token. Isto vai permitir fazer procuras na nossa estrutura de dados de forma rápida e estruturada.

# Passos para executar o Projeto

Utilização do nosso “engine”:

```
usage: engine.py [-h] [-s STOPWORDS] [-m MEMORY] [--store_positions] [--tfidf]
                 input output {tokenizer,simple_tokenizer}

positional arguments:
  input                 Filename or directory with files to index
  output                Filename of the file with the indexer result
  {tokenizer,simple_tokenizer}
                        Indicates which tokenizer the indexer must use

optional arguments:
  -h, --help            show this help message and exit
  -s STOPWORDS, --stopwords STOPWORDS
                        Filename of the stopwords list (ignored if tokenizer
                        is "simple_tokenizer")
  -m MEMORY, --memory MEMORY
                        Percentage of max memory used in the process
  --store_positions     Indicates if indexer stores positions of terms or not
  --tfidf               Indicates if program calculates tfidf or not
```

Execução do exercício 4:

```
usage: ex4.py [-h] [-s STOPWORDS] [-m MEMORY]
              input output {tokenizer,simple_tokenizer}

positional arguments:
  input                 Filename or directory with files to index
  output                Filename of the file with the indexer result
  {tokenizer,simple_tokenizer}
                        Indicates which tokenizer the indexer must use

optional arguments:
  -h, --help            show this help message and exit
  -s STOPWORDS, --stopwords STOPWORDS
                        Filename of the stopwords list (ignored if tokenizer
                        is "simple_tokenizer")
  -m MEMORY, --memory MEMORY
                        Percentage of max memory used in the process
```

# Diagrama de Classes

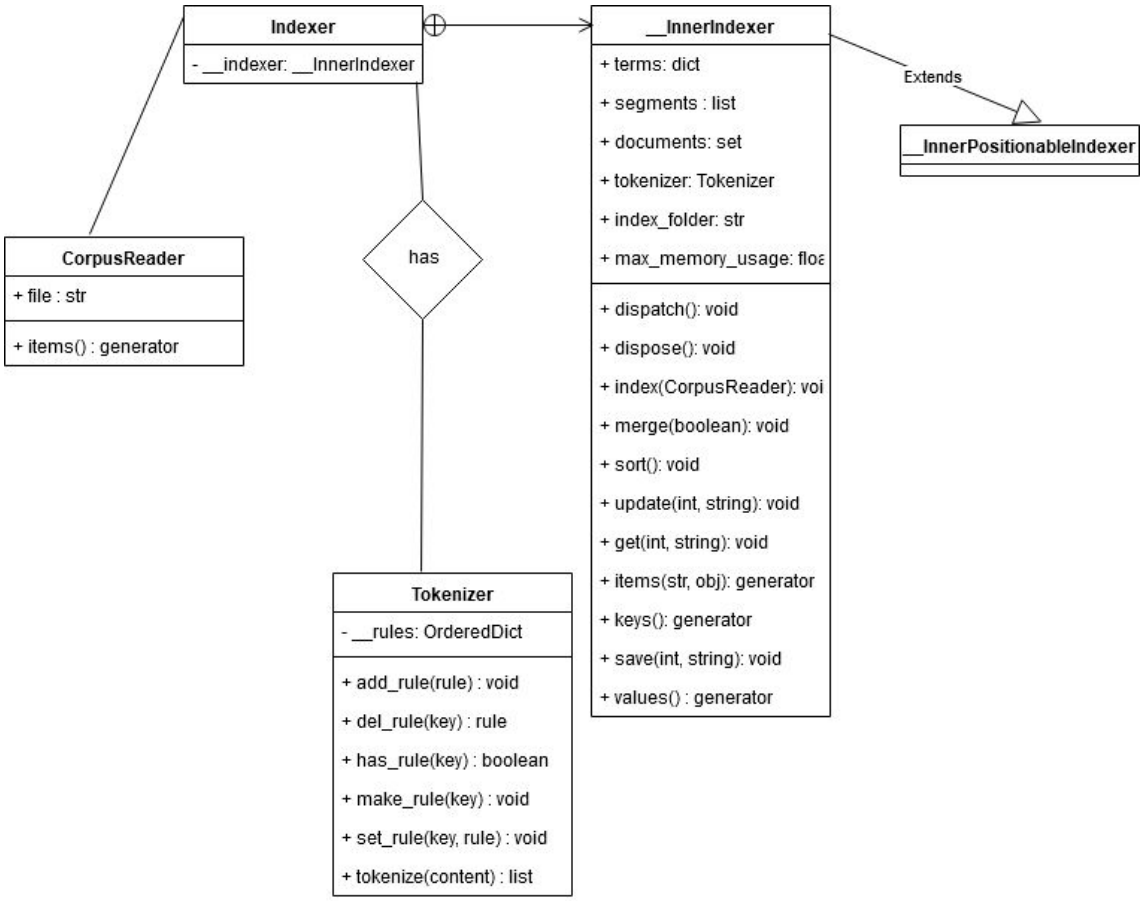

# Diagrama de Workflow

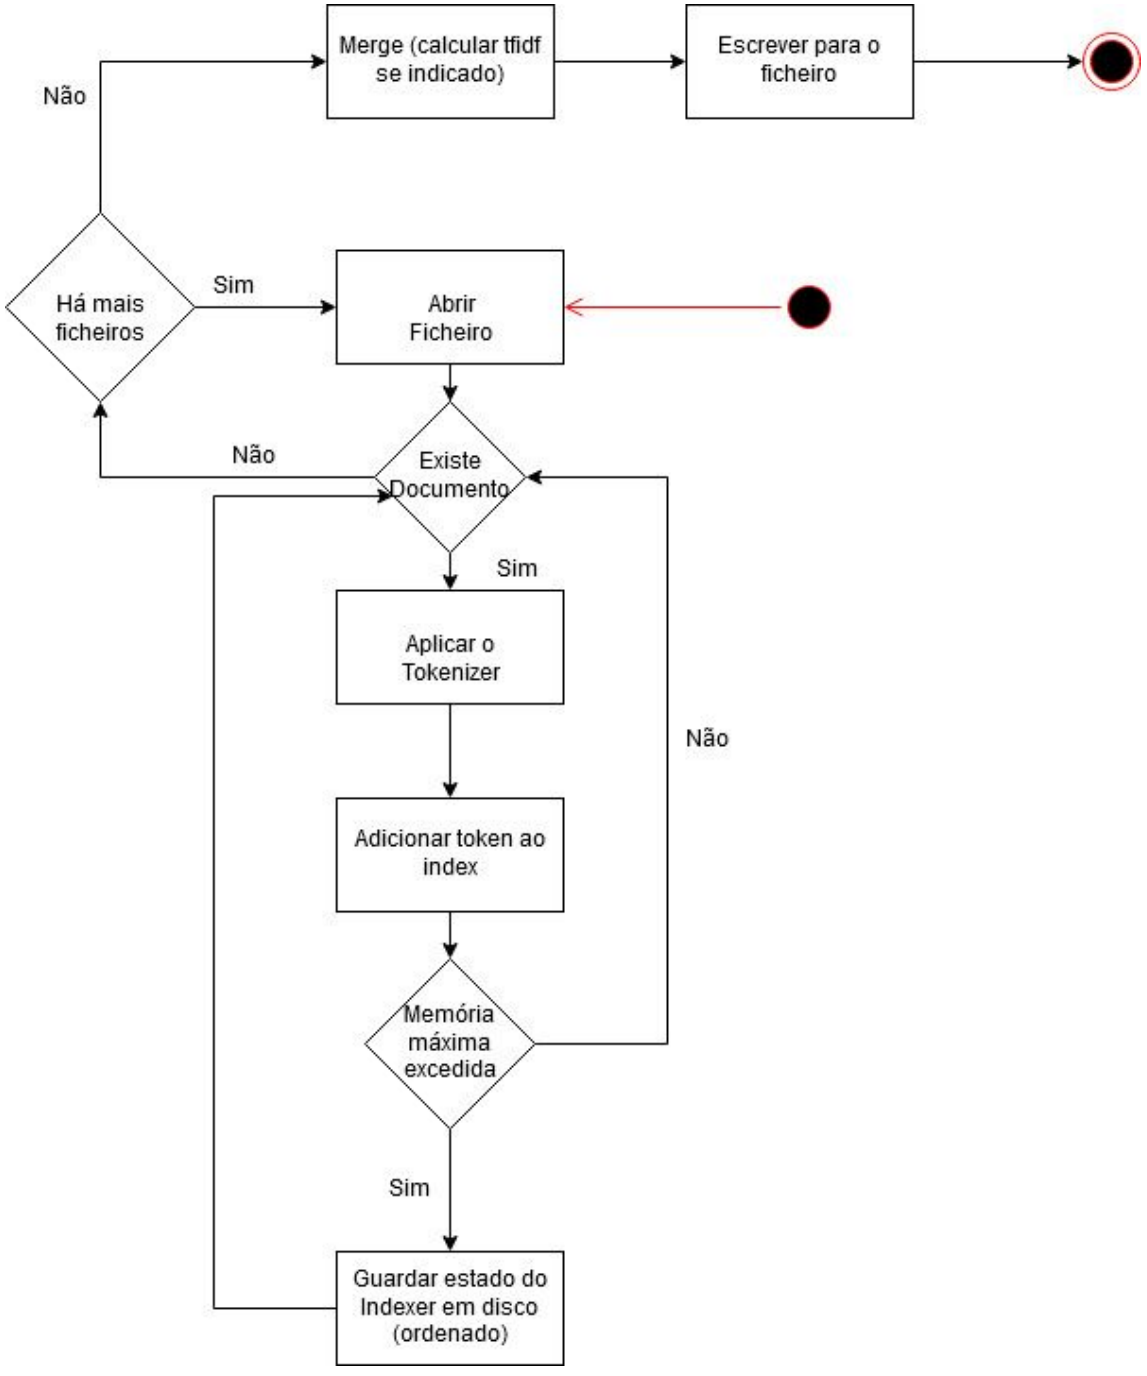


Como se pode observar pelos diagramas, o texto original (documentos) são processados pela classe “CorpusReader”. Esta classe possui apenas um construtor e um método que lê o ficheiro e retorna um gerador que vai retornando um tuplo (pmid

: TI) com o ID do documento (PMID) e com TI correspondente numa string. Isto significa que os dados vão sendo lidos à medida que vão sendo processados.

Os TI's são então processados pela classe Tokenizer que vai aplicar uma série de regras. Estão implementados 2 Tokenizers, o "simple tokenizer" e o "tokenizer". O "simple tokenizer" substitui todos os caracteres não alfabéticos por espaços, substitui todos os caracteres pelo minúsculo correspondente. A divisão dos tokens é efetuada por espaço e são ignorados todos os tokens com menos de 3 caracteres.

Já o "tokenizer" substitui todos os caracteres pelo minúsculo correspondente, substitui apenas certos sinais de pontuação por espaços, sendo eles: ".", ",", "-", "!", "?", ";", "*", "/", "=", "(", ")", "[", "]", ":", "'", "'", "\", "\n", com a exceção do "." quando este é precedido de um único caratere alfabético seguido e no máximo precedido de um caratere alfabético seguido, transformando assim uma sequência deste tipo de pontos num único token, por exemplo, "u.s.a." ou "u.s.a" são ambos convertidos para "usa". Além do ponto, também o "-" não é substituído quando é antecedido e precedido por uma palavra, por exemplo, "algodão-doce". Além disto filtra todas as palavras com menos de 2 carateres, além de utilizar uma *stopword list* para filtrar certas palavras específicas, bem como aplica stemming a todas as palavras. Os tokens, tal como anteriormente são separados utilizando os espaços.

De seguida os tokens são indexados pela classe Indexer que possui um dicionário "terms" que tem a seguinte estrutura:

{token : {doc_id1 : [index1, index2], doc_id2 : [index3]}}

em que token como o próprio nome indica é o token, o doc_id é o PMID do documento, e os index são as posições no texto em que o token apareceu. Esta classe possui o método "update(doc_id, terms)" que sempre que é processado um documento, indexa os tokens desse documento.

Neste processo, caso uma dada quantidade de memória seja excedida, o indexer guarda os tokens atuais (por ordem alfabética) em disco, limpa a memória e continua o processo. No final, ocorre o processo de merge onde o indexer realiza um merge dos vários ficheiros em disco.

Este merge consiste em juntar os dados associados a um dado token que podem estar espalhados pelos vários documentos. Isto é feito de forma ordenada, primeiro escolhe-se o token mais pequeno encontrado em todos os ficheiros. De seguida, volta-se a escolher o token mais pequeno (o anterior já não conta para esta operação) e se esse novo token for igual ao anterior realiza-se o merge, caso contrário guarda-se outro numa lista temporário. Repete-se o processo até que nenhum dos ficheiros gerados pelo processo de indexing contenha tokens. No meio disto, a lista temporária pode ser escrita para disco (caso exceda um dado limite de memória) e guarda-se apenas o bloco (ficheiro) em memória associados ao primeiro e último token dessa lista (isto será útil para carregar o bloco para memória quando necessário). Além

disto pode também ser realizado o cálculo do tfidf. Este é feito quando o token vai para ser escrito na lista temporária.

# Análise de Resultados

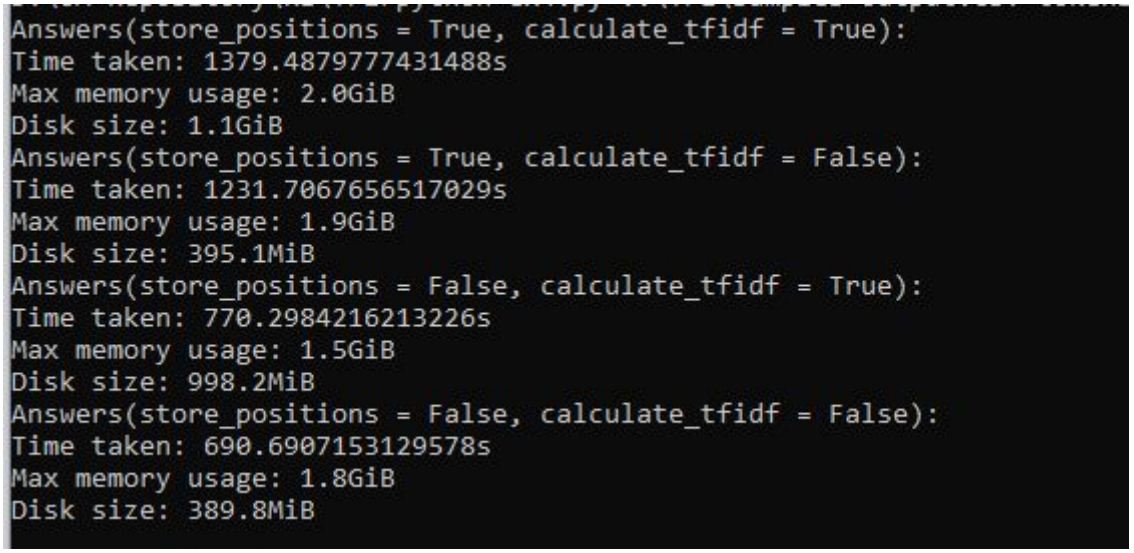


Pode-se observar acima o tempo gasto na indexação (merge incluído), o máximo de memória utilizada pelo processo e o espaço em disco do indexer.

Pode-se verificar então que o tempo gasto na indexação tem um maior aumento quando se guarda as posições, sendo que calcular o tfidf aumenta o tempo, mas numa escala muito menor.

Podemos concluir também que o espaço de disco utilizado é maior quando se calcula o tfidf, sendo que guardar as posições não tem tanta influência.

Por fim o máximo de memória não parece ser afetado por estes dois parâmetros, isto deve-se ao facto de ser imposto um limite máximo de memória que é igual para todos os indexers.

# Conclusão

Com este trabalho aprendemos mais sobre processamento de texto e também sobre as várias tarefas desempenhadas pelos motores de busca como a Google.

Podemos concluir também que os resultados obtidos são muito satisfatórios e fazem sentido de acordo com o que está a ser processado.

# Referências


https://medium.com/@datamonsters/text-processing-in-python-step-tools-and-examples-bf025f872908

https://www.stackoverflow.com

https://medium.com/towards-artificial-intelligence/text-mining-in-python-steps-and-examples-78b3f8fd913b